

UNIVERSITATEA BABEȘ-BOLYAI CLUJ-NAPOCA
FACULTATEA DE MATEMATICĂ ȘI INFORMATICĂ
SPECIALIZAREA MATEMATICĂ INFORMATICĂ

LUCRARE DE LICENȚĂ

Predicting the Virtual Market: Dezvoltarea unui sistem de analiză pentru jocul Counter-Strike2

Conducător științific
Lector Dr. Zsigmond Imre

Absolvent
Popa Alex-Ștefan

ABSTRACT

This paper explores the advanced dynamics of the virtual economy, focusing on the analysis of digital assets traded within the Steam Community Market ecosystem, with a particular emphasis on cosmetic items from Counter-Strike 2 (CS2). As these digital goods have increasingly been perceived as a speculative financial asset class, an acute need has emerged to develop computing tools capable of automating market data collection and providing rigorous price trend forecasts. The fundamental objective of this research is the design and implementation of an integrated software system that harmoniously combines Robotic Process Automation (RPA) technologies, advanced Machine Learning algorithms, and modern web development, offering a comprehensive solution for monitoring and forecasting virtual market trends.

The paper is structured into six essential chapters that describe the entire life cycle of the project:

Chapter 1 presents the technological context and the motivation behind this topic, highlighting the relevance of the virtual economy in the current digital landscape. The research objectives are defined, emphasizing the need to automate repetitive tasks and the added value of algorithmic predictions.

Chapter 2 provides a comprehensive review of the specialized literature, analyzing the evolution of the virtual economy concept and the impact that emerging technologies, such as RPA and artificial intelligence, have on the efficiency of economic processes. Fundamental studies validating the importance of machine learning models in making investment decisions are discussed.

Chapter 3 details the data collection workflow, highlighting the original contribution of utilizing the UiPath platform to develop software robots that extract real-time data from multiple trading marketplaces. This section describes the robotic architecture and the processing logic applied to massive information flows.

Chapter 4 is dedicated to predictive price analysis. It describes the data preprocessing techniques and the implementation of regression and forecasting models, specifically Prophet and XGBoost. The mathematical principles behind these algorithms are explained, and the comparative prediction results are presented, demonstrating the validity of the chosen models.

Chapter 5 introduces the development of the interactive web platform, built on the Dash framework (Python). The resulting interface centralizes the aggregated data and provides the user with a comprehensive suite of tools: graphical visualization of price predictions, a marketplace module that identifies and compares the lowest available prices across various external platforms in real-time, and an original case-opening simulator component that enhances interactivity and user engage-

ment in market exploration.

Finally, Chapter 6 summarizes the conclusions of the paper, reflecting on the impact of the proposed solution and suggesting future development directions, such as the integration of live market APIs or the expansion of ML models to other games in the Steam catalog.

The original contribution of this paper consists of creating a complete, automated end-to-end workflow that eliminates human intervention in data collection and provides end-users with an intuitive, algorithmically backed tool for a deeper understanding of the economic mechanisms within CS2.

Keywords: RPA, Machine Learning, Steam Community Market, CS2, Dash.

Cuprins

1	Introducere	1
1.1	Contextul și motivarea temei	1
1.2	Obiectivele lucrării	1
1.3	Contribuția proprie și rezultate originale	2
1.4	Structura lucrării	2
2	Stadiul actual al cunoașterii	3
2.1	Economia bunurilor virtuale în ecosistemul Steam	3
2.2	Automatizarea proceselor prin RPA	4
2.3	Analiza predictivă a seriilor temporale	5
2.3.1	Modelul Prophet	5
2.3.2	Modelul XGBoost (eXtreme Gradient Boosting)	6
2.3.3	Justificarea abordării comparative	7
2.4	Sinteză	7
3	Arhitectura sistemului și automatizarea colectării datelor	8
3.1	Arhitectura generală a sistemului	8
3.2	Implementarea robotului pentru Web Scraping	9
3.2.1	Fluxul de extracție a datelor	9
3.2.2	Tratarea erorilor și politicile Anti-Scraping	10
3.3	Modelarea și preprocesarea datelor colectate	11
3.3.1	Curățarea datelor brute	13
4	Analiza predictivă a datelor utilizând învățarea automată	14
4.1	Pregătirea setului de date pentru modelare	14
4.1.1	Extragerea și generarea de noi atribute	14
4.1.2	Împărțirea setului de date (Train/Test Split)	14
4.2	Implementarea modelului Prophet	15
4.2.1	Configurarea și antrenarea algoritmului	15
4.3	Implementarea modelului XGBoost	16
4.3.1	Antrenarea și optimizarea hiperparametrilor	16

4.4	Evaluarea și compararea performanțelor	16
5	Dezvoltarea platformei Web și prezentarea rezultatelor	18
5.1	Tehnologii utilizate pentru prezentarea datelor	18
5.2	Arhitectura interfeței cu utilizatorul (UI/UX)	18
5.3	Integrarea și vizualizarea predicțiilor ML	19
5.3.1	Panoul de control (Sidebar / Filtre)	19
5.3.2	Modulul de analiză istorică (EDA)	20
5.3.3	Interpretarea comparativă a indicatorilor numerici	21
5.4	Instrumente interactive adiționale	22
5.4.1	Agregatorul de Marketplace	22
5.4.2	Simulatorul de <i>Case Opening</i>	23
5.5	Sinteza fluxului End-to-End	24
6	Concluzii și direcții viitoare	25
6.1	Sinteza rezultatelor obținute	25
6.2	Contribuții personale	25
6.3	Direcții de dezvoltare ulterioară	26
	Bibliografie	28

Listă de figuri

2.1	Dinamica cererii și ofertei în piețele de bunuri virtuale	4
2.2	Fluxul de lucru al sistemului RPA pentru extragerea datelor de piață	5
2.3	Ciclul de viață al modelului de Machine Learning: Preprocesare și Predicție	6
3.1	Configurarea activității de <i>Extract Table Data</i> în UiPath pentru tabelul istoric de prețuri	9
3.2	Exemplu de date extrase: Structura tabelară a fișierului Excel generat	10
3.3	Fluxul de preprocesare: Main Workflow și preprocesarea datelor extrase	12
3.4	Implementarea pipeline-ului de preprocesare în mediul de dezvoltare	13
4.1	Crearea atributelor de timp și a mediilor mobile	15
4.2	Împărțirea setului de date (80/20) pentru validarea modelului	15
4.3	Configurarea și antrenarea modelului Prophet pentru seria temporală	16
4.4	Implementarea modelului XGBoost: transformarea datelor și antre- narea regresorului	16
4.5	Implementarea funcției de calcul a metricilor de eroare (MAE, RMSE, MAPE)	17
5.1	Interfața principală a platformei Dash	19
5.2	Vizualizarea integrată a predicțiilor și detaliile skin-ului selectat . . .	19
5.3	Vizualizarea comparativă a predicțiilor generate de modelul Prophet vs. XGBoost	20
5.4	Indicatorii de decizie: Tabelul comparativ și modulele de estimare temporală	22
5.5	Interfața modulului Marketplace: Compararea prețurilor în timp real	23
5.6	Case Simulator	24

Capitolul 1

Introducere

1.1 Contextul și motivarea temei

În ultimii ani, piața jocurilor video a depășit granițele divertismentului, transformându-se într-un ecosistem economic complex, definit de schimbul de bunuri virtuale cu valoare reală. Platforma Steam, și în particular jocul Counter-Strike 2 (CS2), reprezintă un exemplu elocvent de „economie virtuală”, unde utilizatorii tranzacționează *skin-uri* a căror valoare este determinată de cerere și ofertă. Această volatilitate a pieței digitale creează o nevoie urgentă de instrumente automatizate care să permită monitorizarea, analiza și prognoza prețurilor, trecând dincolo de simpla intuiție a jucătorului.

Motivația acestei lucrări derivă din dorința de a eficientiza acest proces de analiză prin integrarea unor tehnologii emergente, creând un flux tehnologic automatizat de la sursa datelor până la utilizatorul final.

1.2 Obiectivele lucrării

Obiectivul principal al acestei licențe este dezvoltarea unui sistem informatic integrat, capabil să automatizeze întregul ciclu de viață al datelor de piață. Obiectivele specifice urmărite sunt:

- **Automatizarea colectării și sincronizării datelor:** Utilizarea UiPath pentru extragerea prețurilor de pe platformele de tranzacționare și implementarea unor scripturi Python dedicate pentru actualizarea automată și sincronizarea bazei de date cu sursele externe.
- **Implementarea analizei predictive:** Dezvoltarea unor modele de Machine Learning (Prophet, XGBoost) pentru a anticipa tendințele de piață și a oferi suport decizional avansat.

- **Dezvoltarea interfeței web interactive:** Crearea unei platforme în framework-ul Dash care să integreze trei funcționalități cheie: vizualizarea predicțiilor, un modul de marketplace cu tabel comparativ de prețuri și un simulator de riscuri (case opening simulator).

1.3 Contribuția proprie și rezultate originale

Contribuția principală a acestei lucrări constă în arhitectura unui flux de date *end-to-end*. Am proiectat un sistem în care intervenția umană este minimizată: roboții software UiPath extrag datele, scripturile Python asigură integritatea bazei de date, iar dashboard-ul Dash expune aceste date într-o formă acționabilă. Această abordare transformă datele brute în informații economice valoroase pentru traderii de active digitale.

1.4 Structura lucrării

Lucrarea este structurată în șase capitole:

- **Capitolul 1** prezintă motivația și obiectivele cercetării.
- **Capitolul 2** analizează literatura de specialitate privind economia virtuală și automatizarea proceselor (RPA).
- **Capitolul 3** detaliază arhitectura roboților UiPath și mecanismele de sincronizare a bazei de date prin Python.
- **Capitolul 4** descrie implementarea modelelor de predicție (Prophet, XGBoost).
- **Capitolul 5** explică dezvoltarea platformei web și a celor trei module funcționale.
- **Capitolul 6** sumarizează concluziile și propune direcții de dezvoltare viitoare.

Capitolul 2

Stadiul actual al cunoașterii

Acest capitol analizează fundamentele teoretice necesare dezvoltării sistemului propus, abordând tematici precum economia virtuală a bunurilor digitale, automatizarea colectării datelor prin tehnologii RPA și modelele avansate de predicție a seriilor temporale.

2.1 Economia bunurilor virtuale în ecosistemul Steam

Ecosistemele virtuale au evoluat de la simple spații de interacțiune socială la piețe financiare complexe. Așa cum subliniază literatura de specialitate [NL16], bunurile din Counter-Strike 2 (CS2) funcționează ca active digitale speculative, a căror valoare este guvernată de mecanisme de cerere și ofertă. Această perspectivă este susținută și de cercetările care analizează comportamentul utilizatorilor ca "imigranți" într-o lume virtuală, unde bunurile au valoare reală [Leh05]. Monitorizarea acestor active necesită o abordare tehnologică robustă, capabilă să gestioneze volatilitatea specifică acestor piețe.



Figura 2.1: Dinamica cererii și ofertei în piețele de bunuri virtuale

2.2 Automatizarea proceselor prin RPA

Colectarea manuală a prețurilor de pe multiple platforme de tranzacționare este ineficientă și predispusă la erori umane. Tehnologia RPA (Robotic Process Automation), prin soluții precum UiPath, permite emularea comportamentului uman în interfețele web, fiind esențială pentru *web scraping*-ul la scară largă [Flo20]. Această tehnologie este recunoscută ca fiind disruptivă și capabilă să sporească semnificativ productivitatea prin reducerea muncii manuale repetitive [ISVBV19, TSK22].

În cadrul acestui proiect, roboții software sunt utilizați pentru a extrage datele de piață în timp real, asigurând un flux continuu de informații către baza de date, fără a încălca restricțiile platformelor.




Figura 2.2: Fluxul de lucru al sistemului RPA pentru extragerea datelor de piață

2.3 Analiza predictivă a seriilor temporale

Pentru a oferi suport decizional traderilor, este necesară o componentă predictivă avansată. Lucrarea utilizează o abordare hibridă, comparând două modele de învățare automată cu mecanisme fundamentale distincte:

2.3.1 Modelul Prophet

Modelul Prophet este conceput pentru prognoza seriilor temporale care prezintă sezonabilitate puternică, fiind utilizat pentru a identifica trendurile prețurilor în con-

textul pieței Steam [Rot23]. Acesta excelează în identificarea variațiilor ciclice, fiind ideal pentru dinamica prețurilor skin-urilor de CS2.

2.3.2 Modelul XGBoost (eXtreme Gradient Boosting)

XGBoost este un algoritm de învățare supervizată bazat pe arbori de decizie, utilizat frecvent în optimizarea strategiilor investiționale prin analiza datelor financiare complexe [LWA⁺23]. Spre deosebire de modelele aditive simple, XGBoost analizează relații non-liniare complexe între variabilele de piață, fiind capabil să detecteze schimbări bruște de preț bazate pe volumul de tranzacționare [PS21].




Figura 2.3: Ciclul de viață al modelului de Machine Learning: Preprocesare și Predicție

2.3.3 Justificarea abordării comparative

Implementarea ambelor modele oferă o validare încrucișată a rezultatelor. În timp ce Prophet oferă o perspectivă istorică și sezonieră, XGBoost adaugă precizie prin analiza factorilor corelați (ex: volum, raritate). Această sinergie reduce riscul de eroare, permițând sistemului să ofere estimări mai robuste comparativ cu utilizarea unui singur algoritm.

2.4 Sinteză

Studiul literaturii de specialitate relevă o fragmentare între automatizarea proceselor (RPA) și analiza predictivă (ML). Proiectul de față propune o abordare unitară, de tip *pipeline end-to-end*: datele colectate automat prin RPA sunt prelucrate și utilizate de modelele ML, iar rezultatele sunt expuse printr-un dashboard interactiv în Dash, oferind utilizatorului final o soluție completă de monitorizare a pieței.

Capitolul 3

Arhitectura sistemului și automatizarea colectării datelor

Acest capitol detaliază arhitectura soluției software propuse și modul în care datele necesare pentru antrenarea modelelor predictive sunt extrase din platforma Steam Community Market. Având în vedere lipsa unui API public complet gratuit și nerestricționat pentru istoricul detaliat al prețurilor pe perioade îndelungate, s-a optat pentru utilizarea tehnologiei RPA.

3.1 Arhitectura generală a sistemului

Sistemul dezvoltat reprezintă o soluție *end-to-end* care integrează mai multe tehnologii pentru a atinge obiectivul final: monitorizarea, predicția și vizualizarea evoluției prețurilor pentru activele virtuale din Counter-Strike 2. Fluxul de lucru al aplicației este structurat în patru module principale:

1. **Modulul de extracție (RPA):** Un robot software interacționează cu paginile web ale pieței Steam pentru a descărca istoricul zilnic al prețurilor și volumul de tranzacționare.
2. **Modulul de stocare:** Datele brute extrase sunt transformate și stocate într-o structură relațională, asigurând un acces rapid pentru etapele ulterioare.
3. **Modulul de analiză predictivă:** Modelele de învățare automată (Prophet și XGBoost) preiau datele istorice pentru a genera prognoze.
4. **Modulul de prezentare (Dashboard):** O interfață web interactivă afișează analizele și predicțiile utilizatorului final.

3.2 Implementarea robotului pentru Web Scraping

Componenta RPA a fost dezvoltată utilizând platforma UiPath Studio. Spre deosebire de scripturile tradiționale de scraping care pot fi ușor blocate de măsurile de securitate ale platformelor, UiPath emulează fidel interacțiunea umană cu browserul web, accesând secvențial link-urile aferente skin-urilor de CS2 de interes.

3.2.1 Fluxul de extracție a datelor

Procesul de extragere folosește activități specifice UiPath, precum *Use Application/Browser* pentru navigare și activități de manipulare a interfeței grafice (UI). Deoarece graficele de pe Steam sunt generate dinamic folosind JavaScript, robotul a fost configurat cu selectori avansați pentru a identifica elementele din codul sursă al paginii (DOM) care conțin structurile de date ascunse cu istoricul detaliat (dată, preț de vânzare, cantitate vândută). Aceste date sunt preluate, formatate preliminar și salvate în fișiere locale de tip Excel.




Figura 3.1: Configurarea activității de *Extract Table Data* în UiPath pentru tabelul istoric de prețuri

Name		Price	Converted Price To Double	Date
★ Paracord Knife	Doppler (Minimal Wear)	€343,45	343,45	05/31/2026 19:27:45
★ Paracord Knife	Doppler (Minimal Wear)	€357,03	357,03	05/19/2026 10:55:24
★ Paracord Knife	Doppler (Minimal Wear)	€357,03	357,03	05/19/2026 10:54:08
★ Paracord Knife	Doppler (Minimal Wear)	€357,03	357,03	05/19/2026 00:25:17
★ Paracord Knife	Doppler (Minimal Wear)	€357,03	357,03	05/19/2026 00:17:29
★ Paracord Knife	Doppler (Minimal Wear)	€356,96	356,96	05/18/2026 23:57:47
★ Paracord Knife	Doppler (Minimal Wear)	€356,96	356,96	05/18/2026 17:10:15
★ Paracord Knife	Doppler (Minimal Wear)	\$418.77 USD	418,77	03/16/2026 15:15:11
★ Paracord Knife	Doppler (Minimal Wear)	\$418.77 USD	418,77	03/16/2026 15:13:54
★ Paracord Knife	Doppler (Minimal Wear)	\$418.77 USD	418,77	03/16/2026 15:07:42
★ Paracord Knife	Doppler (Minimal Wear)	\$418.77 USD	418,77	03/16/2026 15:07:08
★ Paracord Knife	Doppler (Minimal Wear)	356,34€	356,34	02/06/2026 16:26:32
★ Paracord Knife	Doppler (Minimal Wear)	\$431.13 USD	431,13	01/22/2026 16:04:43
★ Paracord Knife	Doppler (Minimal Wear)	\$431.13 USD	431,13	01/22/2026 15:52:59
★ Paracord Knife	Doppler (Minimal Wear)	\$433.00 USD	433	01/15/2026 13:49:14
★ Paracord Knife	Doppler (Minimal Wear)	\$433.00 USD	433	01/15/2026 13:41:27
★ Paracord Knife	Doppler (Minimal Wear)	\$433.00 USD	433	01/15/2026 13:40:55
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:14:27
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:14:19
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:09:48
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:09:34
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:08:54
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:08:38
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:08:16
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:07:33
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 15:05:09
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 13:42:12
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 13:38:40
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 13:34:19
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 13:13:09
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 13:06:36
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 13:02:38
★ Paracord Knife	Doppler (Minimal Wear)	\$439.99 USD	439,99	01/08/2026 13:01:16
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 14:00:21
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 11:24:43
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 09:46:53
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 09:43:04
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 09:40:22
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 09:38:14
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 09:08:11
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 09:04:43
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 09:00:39
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 02:00:32
★ Paracord Knife	Doppler (Minimal Wear)	\$405.00 USD	405	12/18/2025 01:54:51
★ Paracord Knife	Doppler (Minimal Wear)	\$404.87 USD	404,87	12/17/2025 02:36:56
★ Paracord Knife	Doppler (Minimal Wear)	\$404.87 USD	404,87	12/17/2025 02:35:56
★ Paracord Knife	Doppler (Minimal Wear)	\$404.87 USD	404,87	12/17/2025 02:32:25
★ Paracord Knife	Doppler (Minimal Wear)	\$404.87 USD	404,87	12/17/2025 02:24:07
★ Paracord Knife	Doppler (Minimal Wear)	\$404.87 USD	404,87	12/16/2025 22:54:26

Figura 3.2: Exemplu de date extrase: Structura tabelară a fișierului Excel generat

3.2.2 Tratarea erorilor și politicile Anti-Scraping

Platforma Steam implementează mecanisme stricte de protecție împotriva cererilor automate excesive, putând returna erori de tipul HTTP 429 (Too Many Requests). Pentru a asigura stabilitatea execuției și a preveni blocarea temporară a adresei IP, robotul a fost echipat cu mai multe mecanisme de siguranță:

- **Blocuri Try-Catch:** Utilizate pentru a intercepta elementele UI care nu se încarcă la timp sau paginile indisponibile, permițând robotului să treacă la următorul item fără a întrerupe întreaga execuție.

- **Latențe artificiale (Delays):** Au fost introduse întârzieri aleatorii între interogări, simulând un comportament natural de navigare.

3.3 Modelarea și preprocesarea datelor colectate

Odată ce datele sunt descărcate de robotul UiPath, ele necesită o etapă riguroasă de preprocesare înainte de a fi livrate algoritmilor de Machine Learning. Datele financiare extrase de pe web sunt rareori într-un format ideal pentru antrenament.




Figura 3.3: Fluxul de preprocesare: Main Workflow și preprocesarea datelor extrase

3.3.1 Curățarea datelor brute

Fișierele generate inițial conțin adesea caractere speciale (simboluri valutare), formate de date inconsistente sau valori nule apărute în zilele fără tranzacții. Folosind scripturi Python și biblioteca Pandas, a fost implementat un pipeline de curățare care realizează următoarele operațiuni:

- Conversia șirurilor de caractere reprezentând prețuri în valori numerice (tip *float*).
- Standardizarea datelor calendaristice în format ISO 8601 (YYYY-MM-DD).
- Tratarea valorilor lipsă (missing values) prin metode de interpolare liniară, menținând astfel continuitatea seriilor temporale necesară modelelor de predicție.

Acest proces garantează că datele care ajung în baza de date și, ulterior, în modelele de inteligență artificială, sunt curate, întregi și structurate corespunzător.

```
with open(FILE_PATH, 'rb') as f:
    excel_file = pd.ExcelFile(f, engine='openpyxl')
    sheets = excel_file.sheet_names
    current_sheet = selected_sheet if selected_sheet and selected_sheet in sheets else sheets[0]
    df = pd.read_excel(excel_file, sheet_name=current_sheet,
                      names=['Item', 'Raw_Price', 'Price', 'Timestamp'])

if df.empty or len(df) < 5:
    return None

df['Timestamp'] = pd.to_datetime(df['Timestamp'], dayfirst=False)
df = df.sort_values(by='Timestamp').drop_duplicates(subset=['Timestamp'])

mean_p, std_p = df['Price'].mean(), df['Price'].std()
df_f = df[(df['Price'] <= mean_p + 6 * std_p) & (df['Price'] >= mean_p - 6 * std_p)].copy()
if df_f.empty: df_f = df.copy()
```

Figura 3.4: Implementarea pipeline-ului de preprocesare în mediul de dezvoltare

Capitolul 4

Analiza predictivă a datelor utilizând învățarea automată

Acest capitol detaliază metodologia de dezvoltare, antrenare și evaluare a modelelor de inteligență artificială utilizate pentru prognoza prețurilor bunurilor virtuale. Având la dispoziție setul de date curățat și structurat în etapa anterioară, s-a procedat la aplicarea tehnicilor de analiză a seriilor temporale utilizând modelele Prophet și XGBoost.

4.1 Pregătirea setului de date pentru modelare

Înainte de faza de antrenament, datele istorice extrase au fost supuse unui proces de inginerie a caracteristicilor (*feature engineering*), esențial pentru îmbunătățirea performanței algoritmilor predictivi.

4.1.1 Extragerea și generarea de noi atribute

Pentru a capta sezonabilitatea și tendințele pieței Steam, din variabila temporală (data tranzacției) au fost derivate atribute suplimentare: ziua săptămânii, luna, anul și indicatori pentru zilele de weekend. De asemenea, pentru modelul XGBoost, au fost calculate medii mobile (*rolling averages*) pe ferestre de 7 și 30 de zile, precum și valorile întârziate ale prețului (*lag features*), care oferă modelului contextul evoluției recente a pieței.

4.1.2 Împărțirea setului de date (Train/Test Split)

Spre deosebire de problemele clasice de clasificare, datele de tip serie temporală nu pot fi împărțite aleatoriu. Pentru a preveni fenomenul de *data leakage* (scurgerea de informații din viitor în trecut), setul de date a fost divizat cronologic. Astfel,

primele 80% din observațiile cronologice au format setul de antrenament (*training set*), în timp ce restul de 20% au fost rezervate exclusiv pentru testare și validare (*testing set*).

```
df_f = df.copy()
df_f['day_of_week'] = df_f['Timestamp'].dt.dayofweek
df_f['month'] = df_f['Timestamp'].dt.month
df_f['rolling_7d'] = df_f['Price'].rolling(window=7).mean()
df_f['rolling_30d'] = df_f['Price'].rolling(window=30).mean()
df_f['lag_1h'] = df_f['Price'].shift(1)

df_f = df_f.dropna().copy()
```

Figura 4.1: Crearea atributelor de timp și a mediilor mobile

```
split_idx = int(len(df_f) * 0.8)
train_df = df_f.iloc[:split_idx]
test_df = df_f.iloc[split_idx:]
```

Figura 4.2: Împărțirea setului de date (80/20) pentru validarea modelului

4.2 Implementarea modelului Prophet

Modelul Prophet, dezvoltat de echipa de cercetare de la Meta, a fost selectat datorită robusteții sale în fața datelor lipsă și a capacității de a modela sezonaliități multiple.

4.2.1 Configurarea și antrenarea algoritmului

Datele au fost redenumite conform cerințelor stricte ale bibliotecii Prophet, utilizând coloanele `ds` pentru componenta temporală și `y` pentru variabila țintă (prețul mediu zilnic). Modelul a fost configurat pentru a detecta automat punctele de schimbare a trendului (*change points*), permițând algoritmului să se adapteze la fluctuațiile bruște cauzate de evenimente externe, cum ar fi actualizările jocului Counter-Strike 2 sau lansarea de noi colecții de skin-uri.

```
df_p = df_f[['Timestamp', 'Price']].rename(columns={'Timestamp': 'ds', 'Price': 'y'})
max_v, min_v = df_f['Price'].max(), df_f['Price'].min()
df_p['cap'], df_p['floor'] = max_v * 1.5, min_v * 0.5
model_p = Prophet(growth='logistic', changepoint_prior_scale=0.005, daily_seasonality=False,
                  weekly_seasonality=False, yearly_seasonality=False)
model_p.fit(df_p)
future_p = model_p.make_future_dataframe(periods=168, freq='1h')
future_p['cap'], future_p['floor'] = max_v * 1.5, min_v * 0.5
forecast_p = model_p.predict(future_p)
f_p_future = forecast_p[forecast_p['ds'] >= df_f['Timestamp'].max()]
```

Figura 4.3: Configurarea și antrenarea modelului Prophet pentru seria temporală

4.3 Implementarea modelului XGBoost

Pentru a capta relațiile non-liniare și interacțiunile complexe dintre volumul de tranzacționare și evoluția prețului, a fost implementat modelul XGBoost (*eXtreme Gradient Boosting*).

4.3.1 Antrenarea și optimizarea hiperparametrilor

XGBoost a fost antrenat pe setul de date extins cu atributele derivate. Pentru a preveni supraînvățarea (*overfitting*), s-a utilizat tehnica de validare încrucișată specifică seriilor temporale (*Time Series Cross-Validation*). Hiperparametrii modelului, precum rata de învățare (*learning rate*), adâncimea maximă a arborilor (*max_depth*) și numărul de estimatori, au fost optimizați iterativ.

```
start_t = df_f['Timestamp'].min()
df_f['t_numeric'] = (df_f['Timestamp'] - start_t).dt.total_seconds()
X_train = df_f[['t_numeric']].values
y_train = df_f['Price'].values

model_xgb = xgb.XGBRegressor(booster='gblinear', n_estimators=100, learning_rate=0.1,
                             objective='reg:squarederror')
model_xgb.fit(X_train, y_train)

last_t = df_f['t_numeric'].max()
future_h = np.array([(last_t + i * 3600) for i in range(0, 169)]).reshape(-1, 1)
preds_xgb = [float(v) for v in model_xgb.predict(future_h)]
```

Figura 4.4: Implementarea modelului XGBoost: transformarea datelor și antrenarea regresorului

4.4 Evaluarea și compararea performanțelor

Pentru a cuantifica precizia celor două modele, predicțiile generate au fost comparate cu valorile reale din setul de testare. Evaluarea obiectivă a fost realizată uti-

lizând trei metrici statistice standard pentru problemele de regresie:

- **Eroarea Medie Absolută (MAE - Mean Absolute Error):** Calculează media diferențelor absolute dintre valorile prezise și cele reale, oferind o interpretare directă a erorii.
- **Rădăcina Erorii Pătratică Medii (RMSE - Root Mean Squared Error):** Penalizează mai sever erorile de predicție majore, fiind utilă pentru a observa cât de mult deviază modelele în perioadele de volatilitate maximă.
- **Eroarea Medie Absolută Procentuală (MAPE - Mean Absolute Percentage Error):** Oferă precizia sub formă procentuală, permițând compararea performanței modelelor pe skin-uri cu ordine de mărime diferite ale prețurilor.

Analiza comparativă a demonstrat diferențe de performanță între cele două abordări. În timp ce Prophet se dovedește a fi superior în trasarea trendului general pe termen lung și izolarea sezonality, XGBoost oferă predicții pe termen scurt mult mai apropiate de prețul real, reușind să integreze cu succes impactul fluctuațiilor volumului de tranzacționare zilnic.

```
y_true = df_f['Price']
prophet_hist_preds = forecast_p['yhat'].iloc[:len(df_f)]

metrics_p = {
    'mae': mean_absolute_error(y_true, prophet_hist_preds),
    'rmse': np.sqrt(mean_squared_error(y_true, prophet_hist_preds)),
    'mape': mean_absolute_percentage_error(y_true, prophet_hist_preds)
}

xgb_preds_train = model_xgb.predict(X_train)

metrics_x = {
    'mae': mean_absolute_error(y_true, xgb_preds_train),
    'rmse': np.sqrt(mean_squared_error(y_true, xgb_preds_train)),
    'mape': mean_absolute_percentage_error(y_true, xgb_preds_train)
}
```

Figura 4.5: Implementarea funcției de calcul a metricilor de eroare (MAE, RMSE, MAPE)

Capitolul 5

Dezvoltarea platformei Web și prezentarea rezultatelor

Acest capitol prezintă componenta finală a sistemului propus, respectiv interfața grafică prin care utilizatorul final interacționează cu datele colectate și cu estimările generate de modelele predictive. Pentru a asigura o experiență fluidă și o vizualizare interactivă a datelor financiare specifice pieței Counter-Strike 2, platforma a fost dezvoltată sub forma unui tablou de bord (*dashboard*) web.

5.1 Tehnologii utilizate pentru prezentarea datelor

Dezvoltarea interfeței a fost realizată utilizând **Dash**, un framework open-source bazat pe Python, creat de Plotly. Alegerea acestui framework a fost motivată de capacitatea sa de a construi aplicații web analitice complexe fără a necesita o separare strictă între backend (codul de Machine Learning) și frontend (HTML/CSS/JavaScript).

Prin intermediul bibliotecii Plotly, graficele generate devin interactive, permițând utilizatorului să efectueze operațiuni de *zoom*, *pan* și să vizualizeze detaliile (*hover*) pentru fiecare dată calendaristică în parte, funcționalități esențiale pentru analiza seriilor temporale financiare.

5.2 Arhitectura interfeței cu utilizatorul (UI/UX)

Aplicația web a fost structurată într-un mod modular și intuitiv, având o tematică vizuală adaptată esteticii comunității de gaming. Layout-ul platformei este împărțit în mai multe secțiuni funcționale de bază:




Figura 5.1: Interfața principală a platformei Dash

5.3 Integrarea și vizualizarea predicțiilor ML



Figura 5.2: Vizualizarea integrată a predicțiilor și detaliile skin-ului selectat

5.3.1 Panoul de control (Sidebar / Filtre)

Partea laterală sau superioară a aplicației conține elementele de control (compo-nente *Dash Core Components* precum `dcc.Dropdown` și `dcc.DatePickerRange`). Aici, utilizatorul poate selecta skin-ul dorit din baza de date actualizată de robotul RPA și poate seta orizontul de timp pentru care dorește să vizualizeze analiza.

5.3.2 Modulul de analiză istorică (EDA)

Odată ce un activ este selectat, aplicația randează graficul cu evoluția istorică a prețurilor pe intervalul de timp selectat. Această secțiune servește drept instrument de analiză tehnică, permițând utilizatorului să observe trendurile de piață și să identifice vizual perioadele de volatilitate maximă.

Nucleul platformei web îl reprezintă secțiunea dedicată predicțiilor. Când un utilizator solicită o estimare, aplicația apelează modelele antrenate descrise în Capitolul 4 (Prophet și XGBoost).

Pentru a spori încrederea utilizatorului în deciziile algoritmilor, rezultatele sunt afișate comparativ:

- Se trasează linia continuă a prețului real (istoric).
- Se adaugă linia punctată a prețului prezis de model.
- În cazul modelului Prophet, pe grafic este randată și "umbra" ce reprezintă intervalul de încredere (*confidence interval*), indicând marginile de eroare posibile (scenariul pesimist vs. scenariul optimist).




Figura 5.3: Vizualizarea comparativă a predicțiilor generate de modelul Prophet vs. XGBoost

5.3.3 Interpretarea comparativă a indicatorilor numerici

Pe lângă componenta vizuală, aplicația oferă un set de indicatori statistici centralizați pentru a facilita luarea deciziilor bazate pe date (data-driven decision making). Această secțiune transformă output-ul brut al modelelor într-o interpretare accesibilă, evidențiind diferențele dintre Prophet și XGBoost.

Tabelul de comparație numerică afișează metrici cheie precum prețul minim, maxim și media estimată, alături de trendul anticipat (creștere sau descreștere). Utilizarea simbolului Δ (delta) oferă utilizatorului o estimare rapidă a profitabilității potențiale, indicând valoarea cu care prețul prognozat diferă de ultimul preț înregistrat.

Pentru a oferi un control granular, interfața integrează două module interactive de estimare:

- **Estimarea pe Ore (1-12h):** Utilă pentru traderii care urmăresc volatilitatea intraday.
- **Estimarea pe Zile (1-7 zile):** Destinată investitorilor care analizează tendințele pe termen scurt și mediu.

Această interactivitate, realizată prin intermediul elementelor de tip *slider*, permite utilizatorului să ajusteze orizontul de predicție în timp real, oferind un context personalizat pentru fiecare decizie de tranzacționare.




Figura 5.4: Indicatorii de decizie: Tabelul comparativ și modulele de estimare temporală

5.4 Instrumente interactive adiționale

Pentru a oferi o utilitate practică sporită și a depăși sfera simplei analize predictive, platforma integrează două instrumente complementare, concepute să asiste utilizatorul în luarea deciziilor financiare: un agregator de piață pentru optimizarea achizițiilor și un simulator de probabilități pentru evaluarea riscului investițional.

5.4.1 Agregatorul de Marketplace

Acest modul adresează problema asimetriei informaționale existente între diversele platforme de tranzacționare. Robotul RPA nu doar că extrage date pentru predicții, dar interoghează în mod activ surse multiple pentru a identifica prețurile de listare în timp real. Astfel, utilizatorul beneficiază de un tabel comparativ care afișează "cea mai bună ofertă" (prețul minim) pentru skin-ul vizat. Această funcționalitate permite traderilor să identifice rapid oportunități de tip *arbitrage* sau să achiziționeze active la prețuri sub media pieței, crescând astfel eficiența investiției.

Live Marketplaces Comparer

Selectează Skin-ul pentru analiză: ★ Paracord Knife | Doppler ✕ ▾



Paracord Knife Doppler (Phase 3) (Factory New)

Found in  **Fever Case**

This fixed-blade survival knife is designed to withstand being used as both a weapon and a tool, such as for setting traps, hunting animals or cutting foliage. The handle is wrapped in a length of multi-purpose paracord. It has been painted with black and silver metallic paints using a marbleizing medium, then candy coated. Getting lost in its color can prove fatal

Variants

FN
MW
ST FN
ST MW

Phases

Phase 1
Phase 2
Phase 3
Phase 4
Ruby
Sapphire
Black Pearl

Float Range 0.00 – 0.08

Cele mai bune oferte pentru: ★ Paracord Knife | Doppler

↕ Condition / Type	↕ Price (€)	↕ Marketplace Source
Factory New (Phase 3)	\$179.78	
Factory New	\$184.52	
Factory New	\$197.38	
Minimal Wear	\$252.10	
Factory New	\$259.99	

Figura 5.5: Interfața modului Marketplace: Compararea prețurilor în timp real

5.4.2 Simulatorul de *Case Opening*

Pentru a completa analiza, am implementat un simulator care vizează componenta de risc. Mulți utilizatori sunt tentați de mecanismele de tip *loot box* (deschiderea cutiilor) fără a cunoaște probabilitățile matematice reale. Simulatorul calculează rata

de rentabilitate (ROI - *Return on Investment*) bazându-se pe cotele oficiale de drop și pe prețurile curente ale skin-urilor extrase.

Această secțiune joacă un rol educativ, demonstrând vizual că, pe termen lung, valoarea medie a obiectelor obținute este adesea inferioară costului cheii, oferind astfel o perspectivă obiectivă asupra riscurilor financiare asociate cu acest tip de "joc de noroc" virtual.



Figura 5.6: Case Simulator

5.5 Sinteza fluxului End-to-End

Implementarea interfeței web încheie ciclul de dezvoltare al aplicației. Sistemul acționează acum ca un organism complet automatizat: robotul UiPath colectează noile date de piață zilnic, baza de date se actualizează, modelele de Machine Learning se recalibrează pe noile informații, iar dashboard-ul Dash preia instantaneu noile valori pentru a fi afișate utilizatorului, validând astfel fezabilitatea tehnică a întregului proiect.

Capitolul 6

Concluzii și direcții viitoare

6.1 Sinteza rezultatelor obținute

Lucrarea de față a abordat o problemă complexă și de actualitate din spațiul economiei virtuale: monitorizarea și predicția valorii activelor digitale din ecosistemul Counter-Strike 2. Obiectivul principal – dezvoltarea unui sistem informatic integrat, capabil să acopere întregul flux de date (*end-to-end*) – a fost atins cu succes prin combinarea mai multor tehnologii moderne.

În prima etapă, limitările impuse de lipsa unui API public complet pentru istoricul pieței au fost depășite prin implementarea unor roboți software în UiPath. Această componentă de automatizare (RPA) a demonstrat o eficiență ridicată în extragerea datelor, eliminând complet intervenția umană. Ulterior, scripturile Python dezvoltate au asigurat curățarea, procesarea și sincronizarea datelor extrase, garantând o actualizare constantă a bazei de date.

Pe baza acestor date, analiza predictivă a fost realizată printr-o abordare comparativă, utilizând algoritmi Prophet și XGBoost. Rezultatele au confirmat ipoteza conform căreia comportamentul pieței virtuale prezintă atât o sezonabilitate pe termen lung (captată eficient de Prophet), cât și fluctuații bruște, non-liniare, corelate cu volumul de tranzacționare (identificate optim de XGBoost).

6.2 Contribuții personale

Contribuția principală a acestei lucrări de licență nu constă doar în aplicarea individuală a unor tehnologii, ci în arhitectura care le leagă într-un produs software funcțional. S-a realizat o trecere de la un simplu experiment de analiză a datelor la o aplicație web interactivă, dezvoltată în framework-ul Dash, care aduce valoare directă utilizatorului final.

Platforma dezvoltată se distinge prin implementarea a trei funcționalități cheie:

- **Modulul de Predicții:** Oferă o vizualizare interactivă a tendințelor de preț, asistând deciziile de investiție pe baza algoritmilor de Machine Learning.
- **Modulul Marketplace:** Introduce un grad ridicat de transparentă pe piață, agregând și afișând comparativ cele mai avantajoase prețuri de pe platforme terțe pentru skin-ul analizat.
- **Simulatorul de Deschidere a Cutiilor (*Case Simulator*):** Adaugă o componentă de analiză a riscului, calculând randamentul investiției (ROI) și educând utilizatorul cu privire la probabilitățile matematice din spatele acestor mecanisme.

6.3 Direcții de dezvoltare ulterioară

Deși sistemul curent îndeplinește toate obiectivele propuse, arhitectura sa modulară permite extinderi viitoare. Câteva direcții de dezvoltare fezabile includ:

- **Scalabilitatea setului de date și diversificarea activelor:** Tranziția de la o analiză axată pe un număr limitat de active la o platformă capabilă să gestioneze întregul inventar de skin-uri și cutii disponibile în Counter-Strike 2. Această extindere ar permite utilizatorilor să caute orice item în baza de date și să simuleze deschiderea oricărui tip de container, oferind o experiență completă și personalizată.
- **Implementarea modelelor de Deep Learning:** Explorarea unor rețele neurale recurente (de tip LSTM) pentru a analiza secvențe temporale și mai complexe, cu potențialul de a crește precizia predicțiilor pe termen foarte scurt.
- **Sistem de alerte în timp real:** Dezvoltarea unui modul de notificări (prin e-mail sau mesagerie instantă) care să alerteze utilizatorul atunci când prețul unui anumit item scade sub un prag definit sau când tabelul de Marketplace identifică un preț mult sub media pieței (oportunitate de tip *arbitrage*).
- **Extinderea către alte ecosisteme:** Adaptarea roboților RPA și a structurii bazei de date pentru a monitoriza bunuri virtuale din alte jocuri cu economii similare, cum ar fi Dota 2 sau Rust.
- **Autentificarea utilizatorilor:** Adăugarea unui sistem de conturi care să permită salvarea unui portofoliu virtual, calculând astfel profitul sau pierderea la nivelul întregului inventar deținut de un utilizator.

În concluzie, lucrarea demonstrează că aplicarea riguroasă a metodelor cantitative, susținută de automatizarea colectării datelor, poate transforma piața speculativă a bunurilor virtuale într-un mediu predictibil și transparent, oferind un avantaj decizional considerabil participanților la această economie.

Bibliografie

- [Flo20] Marcu Florentina. Web data extraction with robot process automation. study on linkedin web scraping using uipath studio. *Annals of Constantin Brancusi University of Targu-Jiu. Engineering Series*, 1, 2020.
- [ISVBV19] Lucija Ivančić, Dalia Suša Vugec, and Vesna Bosilj Vukšić. Robotic process automation: systematic literature review. In *International Conference on Business Process Management*, pages 280–295. Springer, 2019.
- [Leh05] Vili Lehdonvirta. Virtual economics: applying economics to the study of game worlds. In *Proceedings of the 2005 Conference on Future Play (Future Play 2005)*, Lansing, MI, 2005.
- [LWA⁺23] Jiaqi Li, Xiaoyan Wang, Saleem Ahmad, Xiaobing Huang, and Yousaf Ali Khan. Optimization of investment strategies through machine learning. *Heliyon*, 9(5), 2023.
- [NL16] Mohamed Nazir and Carrie Siu Man Lui. A brief history of virtual economy. *Journal for Virtual Worlds Research*, 9(1), 2016.
- [PS21] Akhilesh Prasad and Arumugam Seetharaman. Importance of machine learning in making investment decision in stock market. *Vikalpa*, 46(4):209–222, 2021.
- [Rot23] Matthias Roth. Predicting price trends of digital products using various forecasting techniques: on the example of the steam community market. Master’s thesis, Universidade Catolica Portuguesa (Portugal), 2023.
- [TSK22] Komal Tathe, Sanjot Sharma, and Jyoti Kharade. Data collection using web scrapping with robotic process automation. *Peer-Reviewed, Open Access, Fully Refereed International Journal*, 4, 2022.